

Métodos para identificação de tópicos em textos

Daiane A Zuanetti
Edvaldo C Coelho Filho
Reinaldo Cardoso Anacleto
DEs – UFSCar
PIPGes – São Carlos

Semana de Estatística e Ciência de Dados UFPR – 2026

Nos últimos anos, análise/construção de textos tem sido muito discutida na estatística, computação, etc, principalmente devido ao sucesso e utilidade do ChatGPT, BERT, DeepSeek, etc.

Muitos modelos e métodos estatísticos, matemáticos, computacionais estão disponíveis e sendo pesquisados para desempenhar diferentes tarefas, tais como:

- métodos de pré-processamento de dados;
- modelos não supervisionados paramétricos e não-paramétricos;
- modelos supervisionados paramétricos e não-paramétricos;
- entre outros.

Nesse seminário, abordamos métodos de pré-processamento de textos e dois modelos estatísticos para a análise (modelagem) de tópicos (assuntos) extraídos automaticamente de um conjunto de textos (*corpus*). São eles:

- modelo de mistura; e
- e alocação latente de Dirichlet (LDA, do inglês *latent Dirichlet allocation*).

Temos também métodos mais matemáticos, entre eles a fatoração de matrizes não-negativas (NMF).

Além de modelar (identificar e descrever) os tópicos dos textos, eles podem ser utilizados para análise de agrupamento dos textos, sistema de recomendação de textos, etc.

Métodos de pré-processamento de textos

Dentre as diversas técnicas que podem ser usadas para esta finalidade, estão:

- Tokenização: separação de cada uma das palavras, delimitando seus inícios e fins, desconsiderando, por exemplo, os espaços em branco, as pontuações;
- *Case Folding*: padronização das letras das palavras em maiúsculas ou minúsculas, extração de caracteres especiais, etc;
- Remoção de *stopwords*: consiste na exclusão, dentro de cada texto, de palavras que, em geral, são consideradas irrelevantes, tais como artigos e pronomes;
- *Stemming*: processo que visa reduzir as diferentes formas de uma palavra ao seu radical comum. **Exemplo:** as palavras “corra”, “corrida”, “correram” poder ser representadas por “corr”;
- Lematização: processo que reduz palavras flexionadas ao seu lema (forma canônica ou de dicionário). **Exemplo:** as palavras “correrão”, “correram”, “corridos” poder ser representadas por “correr”.

O vocabulário (ou dicionário) é então criado como sendo o conjunto de todas as palavras dispostas em cada um dos textos que serão analisados.

Entre as técnicas de representação numérica dos textos, se destaca a **bag of words**. Ela contabiliza a presença/ausência ou frequência das palavras do dicionário em cada um dos textos.

Como exemplo, considere os textos abaixo:

- 1) Zeca odeia assistir TV;
- 2) Ana ama assistir filmes.

Tabela: Exemplo *bag-of-words* dos textos acima.

	Zeca	odeia	assistir	TV	Ana	ama	filmes
Texto 1	1	1	1	1	0	0	0
Texto 2	0	0	1	0	1	1	1

Nesse trabalho,

consideramos a estrutura *bag-of-words* com a frequência de cada palavra em cada texto.

Outros métodos que também têm sido muito utilizados para representar numericamente os textos são os TF-IDF (*Term Frequency - Inverse Document Frequency*).

Essas representações desconsideram a ordem das palavras no texto (contexto), mas outros métodos, tais como a vetorização das palavras, também podem ser utilizados para representá-las. O Word2vec é um exemplo de vetorização de palavras que considera o contexto (palavra que acontece antes e depois) de cada palavra.

Modelo de mistura

Seja V o número de palavras do dicionário, dispostas conforme a estrutura *bag-of-words*, $\mathbf{w}_j$ o vetor que representa a quantidade de vezes que cada uma das V palavras do vocabulário aconteceram no documento j e n_{dj} a quantidade de palavras presentes no documento j , temos que

$$\mathbf{w}_j = (w_{j1}, \dots, w_{jV}) \sim \text{Multinomial}(n_{dj}, \phi_j = (\phi_{j1}, \dots, \phi_{jV})),$$

em que $\sum_{v=1}^V w_{jv} = n_{dj}$.

Assumindo m o número de documentos analisados e que cada um desses documentos pode ser proveniente de 1 de K tópicos (assuntos) diferentes, definimos uma variável aleatória discreta não-observável (latente) S_j que representa de qual tópico o documento j é proveniente, $j = 1, \dots, m$ e $S_j \in \{1, \dots, K\}$, com

$$P(S_j = k) = \theta_k,$$

em que $0 \leq \theta_k \leq 1$ e $\sum_{k=1}^K \theta_k = 1$.

Por fim e se soubéssemos de qual tópico (assunto) cada documento é proveniente, temos:

$$\mathbf{w}_j | S_j = k \sim \text{Multinomial}(n_{d_j}, \phi_k = (\phi_{k1}, \dots, \phi_{kV})),$$

em que ϕ_{kv} representa a probabilidade de ocorrência da v -ésima palavra no k -ésimo tópico.

Seja $\mathbf{X} = (\mathbf{w}_1, \dots, \mathbf{w}_m)^T$, a função de verossimilhança aumentada do modelo de mistura é dada por

$$\prod_{k=1}^K \left(\theta_k^{m_k} \phi_{k1}^{\sum_{j=1}^m w_{j1} I(S_j=k)} \dots \phi_{kV}^{\sum_{j=1}^m w_{jV} I(S_j=k)} \right),$$

em que m_k é o número de documentos alocados no tópico k e $\sum_{j=1}^m w_{j1} I(S_j = k)$ é o número de vezes que a palavra 1 aparece em documentos do tópico k .

Assumindo uma abordagem de estimação Bayesiana paramétrica, as distribuições a priori conjugadas são:

- 1 $\theta = (\theta_1, \dots, \theta_K) \sim \text{Dirichlet}(\alpha = (\alpha_1, \dots, \alpha_K))$, em que $0 \leq \theta_k \leq 1$ e $\sum_{k=1}^K \theta_k = 1$;
- 2 $\phi_k = (\phi_{k1}, \dots, \phi_{kV}) \sim \text{Dirichlet}(\beta_k = (\beta_{k1}, \dots, \beta_{kV}))$, em que $0 \leq \phi_{kv} \leq 1$ e $\sum_{v=1}^V \phi_{kv} = 1$.

E as distribuições condicionais completas a posteriori para simularmos uma amostra MCMC da distribuição a posteriori conjunta do modelo, são:

❶ $\pi(\theta | \dots) \propto \prod_{k=1}^K \theta_k^{m_k + \alpha_k - 1};$

❷ $\pi(\phi_k | \dots) \propto \prod_{v=1}^V \phi_{kv}^{\sum_{j=1}^m w_{jv} I(S_j=k) + \beta_{kv} - 1};$

❸ A probabilidade a posteriori de $S_j = k$ pode ser dada por

$$P(S_j = k | \mathbf{w}_j, \theta, \phi) = \frac{\theta_k f(\mathbf{w}_j | \phi_k)}{\sum_{t=1}^K \theta_t f(\mathbf{w}_j | \phi_t)},$$

para $k = 1, \dots, K$, em que $f(\mathbf{w}_j | \phi_k)$ é a função densidade da *Multinomial*(n_{d_j}, ϕ_k) calculada em $\mathbf{w}_j$.

Problema

O número K de tópicos (assuntos) precisa ser conhecido ou então ajustamos o modelo para vários valores de K e escolhemos (usando alguma métrica) o modelo mais adequado para os textos em análise.

Na inferência Bayesiana, existem algumas alternativas para estimarmos o melhor valor de K junto com a estimação do modelo. São elas:

- algoritmo Reversible Jump (Green, 1995);
- inferência Bayesiana não-paramétrica (usando o Processo de Dirichlet), Ferguson (1973), ou suas extensões.

Estimação Bayesiana não-paramétrica

Assumindo um modelo hierárquico, um processo Dirichlet (DP) é dado por

$$\begin{aligned} \mathbf{w}_j \mid \phi_j &\stackrel{\text{indep}}{\sim} \text{Multinomial}(n_{d_j}, \phi_j = (\phi_{j1}, \dots, \phi_{jV})) \\ \phi_j \mid G &\stackrel{\text{iid}}{\sim} G \text{ and } G \sim DP(\alpha G_0), \end{aligned} \quad (1)$$

em que α é o parâmetro de massa total e G_0 é a distribuição base de probabilidade.

Distribuição de S_j :

$$p(S_j = k \mid \mathbf{s}^-) \propto \begin{cases} m_k^-, & \text{para } k = 1, \dots, K^- \\ \alpha & \text{para } k = K^- + 1, \end{cases} \quad (2)$$

e usando o Teorema de Bayes para combiná-la com as informações dos dados,

$$p(S_j = k \mid \mathbf{s}^-, \mathbf{X}) \propto \begin{cases} m_k^- p(\mathbf{w}_j \mid \mathbf{s}^-, \mathbf{X}^-), & \text{para } k = 1, \dots, K^- \\ \alpha h_0(\mathbf{w}_j), & \text{para } k = K^- + 1. \end{cases} \quad (3)$$

LDA (Blei, Ng e Jordan, 2003)

A principal diferença em relação ao modelo de mistura é que, em vez de alocarmos o documento todo para um único tópico, alocamos cada palavra de cada documento em um tópico, ou seja, um documento pode conter palavras de vários tópicos diferentes.

Seja $\mathbf{Y}_j = (Y_{j1}, \dots, Y_{jn_{d_j}})$ o vetor que representa cada uma das palavras presentes no documento j . Como a ordem das palavras não é considerada, a representação *bag of words* também pode ser utilizada para representar cada documento.

Para a i -ésima palavra do j -ésimo documento, simbolizada por y_{ji} , definimos Z_{ji} , $j = 1, \dots, m$, $i = 1, \dots, n_{d_j}$, que identifica com qual tópico essa palavra é associada, consequentemente $Z_{ji} \in \{1, \dots, K\}$ e

$$P(Z_{ji} = k) = \theta_{jk},$$

em que $0 \leq \theta_{jk} \leq 1$ e $\sum_{k=1}^K \theta_{jk} = 1$.

Por fim, temos que $Y_{ji}|Z_{ji} = k \sim \text{Discreta}(\phi_k = (\phi_{k1}, \dots, \phi_{kV}))$.

A função de verossimilhança do LDA é dada por

$$L(\theta, \phi | \mathbf{Z}, \mathbf{Y}) = f(\mathbf{Z}, \mathbf{Y} | \theta, \phi) \propto \left(\prod_{k=1}^K \prod_{j=1}^m \theta_{jk}^{n_{jk}} \right) \left(\prod_{k=1}^K \prod_{v=1}^V \phi_{kv}^{m_{kv}} \right),$$

em que n_{jk} é o número de palavras do j -ésimo documento associadas ao tópico k e m_{kv} é o número de vezes que a palavra v do vocabulário acontece no tópico k .

Assumindo uma abordagem de estimação Bayesiana paramétrica, as distribuições a priori conjugadas são:

- 1 $\theta_j = (\theta_{j1}, \dots, \theta_{jK}) \sim \text{Dirichlet}(\alpha_j = (\alpha_{j1}, \dots, \alpha_{jK}))$, em que $0 \leq \theta_{jk} \leq 1$ e $\sum_{k=1}^K \theta_{jk} = 1$;
- 2 $\phi_k = (\phi_{k1}, \dots, \phi_{kV}) \sim \text{Dirichlet}(\beta_k = (\beta_{k1}, \dots, \beta_{kV}))$, em que $0 \leq \phi_{kv} \leq 1$ e $\sum_{v=1}^V \phi_{kv} = 1$.

E as distribuições condicionais completas a posteriori para simularmos uma amostra MCMC da distribuição a posteriori conjunta do modelo, são:

$$\textcircled{1} \quad \pi(\theta_j | \dots) \propto \prod_{k=1}^K \theta_{jk}^{n_{jk} + \alpha_{jk} - 1};$$

$$\textcircled{2} \quad \pi(\phi_k | \dots) \propto \prod_{v=1}^V \phi_{kv}^{m_{kv} + \beta_{kv} - 1};$$

$\textcircled{3}$ A probabilidade a posteriori de $Z_{ji} = k$ pode ser dada por

$$P(Z_{ji} = k | Y_{ji} = v, \mathbf{Y}_{-ji}, \mathbf{Z}_{-ji}) \propto \frac{m_{kv}^{-ji} + \beta_{kv}}{n_k^{-ji} + \sum_{v=1}^V \beta_{kv}} \frac{n_{jk}^{-ji} + \alpha_{jk}}{n_{dj}^{-ji} + \sum_{k=1}^K \alpha_{jk}}.$$

A definição Bayesiana não-paramétrica do LDA se dá através do Processo de Dirichlet Hierárquico (HDP – Teh, Jordan, Beal e Blei, 2006).

Assumindo um modelo hierárquico, um HDP é dado por

$$\begin{aligned} y_{ji} \mid \phi_{ji} &\overset{indep}{\sim} Discreta(\phi_{ji} = (\phi_{ji1}, \dots, \phi_{jiV})) \\ \phi_{ji} \mid G_j &\overset{iid}{\sim} G_j, G_j \mid G_0 \sim DP(\alpha G_0) \text{ and } G_0 \sim DP(\beta H_0), \end{aligned} \quad (4)$$

em que α e β são parâmetros de massa total e G_0 são distribuições base de probabilidade.

Métricas para seleção de K

- Log-verossimilhança;
- Perplexidade: definida como

$$\text{perplexidade} = \exp \left(-\frac{\log L(\theta, \phi | \mathbf{S}, \mathbf{X})}{\sum_{j=1}^m n_{d_j}} \right);$$

- *Pointwise Mutual Information* (PMI): Ordenando as palavras da mais frequente (propícia) até a menos dentro de cada tópico, temos o vetor $\mathbf{c}_k = (c_{k1}, \dots, c_{kL})$, em que c_{kL} é a L -ésima palavra mais provável do tópico k . É definida como

$$\text{PMI} = \frac{\sum_{k=1}^K \sum_{r=1}^{L-1} \sum_{s=2}^L \log \frac{P(c_{kr}, c_{ks})}{P(c_{kr})P(c_{ks})}}{K \frac{L!}{2!(L-2)!}}, \forall r < s,$$

em que $P(c_{kr})$ é a probabilidade de ocorrer a palavra c_{kr} dentro de um documento e $P(c_{kr}, c_{ks})$ é a probabilidade de ocorrerem ambas as palavras, c_{kr} e c_{ks} , dentro de um mesmo documento;

- *Normalized Pointwise Mutual Information* (NPMI): que normaliza o valor do PMI para $[-1,1]$ e definida como

$$\text{NPMI} = \frac{\sum_{k=1}^K \sum_{r=1}^{L-1} \sum_{s=2}^L \frac{\log \frac{P(c_{kr}, c_{ks})}{P(c_{kr})P(c_{ks})}}{-\log P(c_{kr}, c_{ks})}}{K \frac{L!}{2!(L-2)!}}, \forall r < s;$$

- *Log Conditional Probability* (LCP): definida como

$$\text{LCP} = \frac{\sum_{k=1}^K \sum_{r=1}^{L-1} \sum_{s=2}^L \log \frac{P(c_{kr}, c_{ks})}{P(c_{ks})}}{K \frac{L!}{2!(L-2)!}}, \forall r < s.$$

Por que não critérios de seleção mais comumente usados na Estatística, tais como: BIC, DIC, WAIC, WBIC?

Uma opção é o sBIC (Drton e Plummer, 2017).

Banco de dados *BBC Sport*

- Dispõe de $m = 737$ documentos, com $V = 4613$ palavras (termos) no total;
- É composto por notícias esportivas separadas e classificadas previamente por especialistas em 5 esportes: atletismo, críquete, futebol, rúgbi e tênis, publicadas entre 2004 e 2005;
- Os documentos possuem, em média, 166 termos, com o mínimo de 50 e o máximo de 888 palavras, ou seja, se tratam de textos de médio comprimento;
- Variamos a quantidade de tópicos em $K = 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 25, 30, 35, 40, 45, 50, 75, 100, 125, 150, 175, 200, 250, 300, 400$ e 500 para que fossem feitos os ajustes do NMF e modelos de LDA e MM e, posteriormente, o cálculo das métricas que auxiliam na escolha do melhor número de tópicos.




Figura: *BBC Sport* - Log-verossimilhança por número de tópicos.





Figura: *BBC Sport* - sBIC por número de tópicos.





Figura: *BBC Sport* - PMI por número de tópicos.





Figura: *BBC Sport* - NPMI por número de tópicos.





Figura: *BBC Sport* - LCP por número de tópicos.

Abordagens Bayesianas não-paramétricas

- MM via DP varia entre 5 grupos (53.6%) e 4 grupos (46.4%);
- LDA via HDP estima 6 grupos (98.4%) e 7 grupos (1.6%).

Analisando os modelos com $K = 5$

Tabela: *BBC Sport* - Percentual dos tópicos por esporte via MM.

	Atletismo	Críquete	Futebol	Rugby	Tênis
Tópico 1	-	0.016	0.868	-	-
Tópico 2	0.990	0.218	0.034	0.184	0.090
Tópico 3	-	-	0.079	0.340	-
Tópico 4	0.010	-	0.019	0.476	0.910
Tópico 5	-	0.766	-	0.019	-

Tabela: *BBC Sport* - 10 palavras mais prováveis por tópico via MM.

Tópico 1	Tópico 2	Tópico 3	Tópico 4	Tópico 5
game	world	ireland	play	test
player	olymp	minut	game	play
play	win	england	win	england
club	year	side	england	pakistan
chelsea	test	ball	first	seri
arsen	athlet	win	against	first
league	time	game	open	ball
win	race	try	match	run
football	indoor	penalti	world	team
unit	team	itali	two	two

Observações

- As metodologias conseguiram separar satisfatoriamente os documentos nos tópicos esportivos;
- O NMF não quantifica a incerteza do agrupamento;
- O LDA tende a escolher um número mais de tópicos;
- O MM apresentou uma taxa de classificação ligeiramente melhor que o LDA quando comparada à classificação dos especialistas.

Músicas mais tocadas nas rádios brasileiras

- buscamos no site **mofolandia** as 100 músicas mais tocadas nas rádios brasileiras, incluindo faixas nacionais e internacionais, de 1958 a 2017. Esse site fornece informações, como nome da música, artista e ano correspondente;
- na segunda etapa, buscamos as letras de cada música no site **Letras.mus.br**;

Tabela: Primeiras linhas do banco de dados construído.

	Nome	Artista	Ano	ID	Letra
1	Little Darling	Lana Bittencourt	1958	5801	Eye, yi-eye-eye-eye...
2	Cabecinha no Ombro	Alcides Gerardi	1958	5802	Encosta a tua cabecinha...
3	Sereno	Paulo Molin	1958	5803	Deixa assim como está, sereno...
4	Ouça	Maysa	1958	5804	Ouça, vá viver Sua vida ...
5	Nel Blu Dipinto Di Blu	Domenico Modugno	1958	5805	Penso che un sogno così ...
6	Fascinação	Gilberto Alves	1958	5806	Os sonhos mais lindos sonhei...

O *corpus* deste estudo totaliza 5.978 músicas e a base de dados ao todo conta com 2.196 artistas únicos.

Tabela: Top 11 artistas com canções mais tocadas.

	Artista	Frequência
1	Roberto Carlos	79
2	Zezé Di Camargo & Luciano	42
3	Bruno & Marrone	41
4	Elis Regina	29
5	Beatles	26
6	Ivete Sangalo	26
7	Elton John	25
8	Gal Costa	25
9	Luan Santana	25
10	Madonna	25
11	Skank	25

Pré-processamento

- Identificação da língua de cada música e filtro apenas das em português;
- pré-processamento como dito antes, usando lematização;
- exclusão das palavras muito e pouquíssimo frequentes.




Figura: Proporção de músicas em português e inglês por ano.

O modelo de mistura não-paramétrico foi processado e identificou 85 tópicos.




Figura: Distribuição da frequência de músicas por grupos.

Tabela: Palavras mais frequentes por tópico.

Posição	Tópico 2	Tópico 12	Tópico 7	Tópico 6	Tópico 13	Tópico 9	Tópico 40	Tópico 15	Tópico 10	Tópico 26
1	nunca	sol	chorar	beijo	chorar	ama	ano	baby	maria	amigo
2	esquecer	ceu	sofrer	boca	sofrer	louco	demais	gostar	jesus	cantar
3	perder	lua	morrer	beijar	ligar	beijo	achar	sim	pai	canto
4	voltar	flor	ninguem	desejo	saudade	boca	nascer	gosto	santo	novo
5	tentar	mar	dor	corpo	esquecer	namorar	dez	entao	deus	ela
6	preciso	sonho	perder	sentir	voltar	faco	rua	palavra	cristo	forte
7	saudade	estrela	feliz	paixao	pedir	demais	cara	ouvir	mao	dor
8	sonho	luz	adeus	sinto	ninguem	fico	menino	mudar	ano	vivo
9	demais	encontrar	voltar	vejo	novo	serio	mil	hoje	crer	melhorar
10	ama	vento	embora	louco	sair	apaixonar	atra	luz	ninguem	cancao

Proporção de músicas dos tópicos 2 e 12 ao longo dos anos




Figura: Proporção de músicas por ano dos tópicos 2 (Melancolia e Distanciamento Amoroso) e 12 (Natureza e Poesia).




Figura: Proporção de músicas por ano dos tópicos 6 (Paixão Física e Atração Sensual) e 7 (Melancolia e Drama).

Proporção de músicas dos tópicos 26 e 10 ao longo dos anos



Figura: Proporção de músicas por ano dos tópicos 26 (Música e Canto) e 10 (Religiosidade e Fé).

Também encontramos tópicos menores, mas interessantes, com músicas que possuem palavras:

- em inglês;
- associadas ao samba;
- com referência ao Brasil (tons celebrativos ou críticos).

E muitas vezes a mudança de comportamento parece estar associada a alterações sociais e políticas no Brasil.

Muito obrigada!

Daiane Aparecida Zuanetti

email: dzuanetti@ufscar.br